

Peramalan Harga Saham PT Bank Central Asia Tbk (BBCA.JK) Menggunakan Metode Facebook Prophet

Dimas Pasha Akrilian¹ , Shata Alwan Jalaluddin¹ , Aaron Christian Daniel¹ , Aufaa Zakki Maulidan¹ 

¹ Department of Statistics and Data Science, Faculty of Mathematics and Natural Sciences, Universitas Negeri Semarang, Indonesia

*Corresponding author, email: dimaspasha49@students.unnes.ac.id

May 21, 2026

Abstract

The stock market is one of the most dynamic investment instruments, heavily influenced by economic, political, and market psychology factors. PT Bank Central Asia Tbk (BBCA.JK) is among the most liquid and largest market-capitalization banking stocks on the Indonesia Stock Exchange, making accurate price forecasting critically important for investors and financial decision-makers. This study aims to forecast the daily closing price of BBCA.JK using the Facebook Prophet method, a time-series decomposition model based on trend, seasonal, and holiday components developed by Meta's Core Data Science team. The dataset consists of 1,787 daily closing price observations spanning from January 1, 2019 to May 8, 2026, sourced from Yahoo Finance. The analysis covers data exploration and visualization, identification of trend and seasonal components, stationarity testing via the Augmented Dickey-Fuller (ADF) test, Prophet model fitting, model evaluation, and five-period-ahead forecasting. Results indicate that the Prophet model effectively captures trend and seasonal patterns in stock price data with satisfactory predictive performance. Short- and medium-term forecasts suggest discernible price movement tendencies that may serve as preliminary references for investors. This study contributes to the application of modern decomposition-based time-series methods in the context of the Indonesian capital market.

Keywords: time series, stock price forecasting, Facebook Prophet, BBCA.JK, Augmented Dickey-Fuller

1 Pendahuluan

Pasar modal merupakan salah satu pilar penting dalam sistem keuangan suatu negara karena berfungsi sebagai wahana mobilisasi dana jangka panjang antara pihak yang memiliki kelebihan modal dengan pihak yang membutuhkan pembiayaan [1]. Dalam konteks Indonesia, Bursa Efek Indonesia (BEI) telah menjadi barometer kondisi perekonomian nasional, dengan kapitalisasi pasar yang terus berkembang seiring pertumbuhan jumlah investor ritel maupun institusional. Salah satu saham yang paling diperhatikan di BEI adalah saham PT Bank Central Asia Tbk dengan kode emiten BBCA.JK, yang secara konsisten menempati posisi teratas dalam hal kapitalisasi pasar dan volume perdagangan harian. Kondisi ini menjadikan BBCA.JK sebagai objek kajian yang relevan dan strategis dalam penelitian pasar modal di Indonesia.

Harga saham merupakan variabel yang bersifat sangat dinamis dan dipengaruhi oleh interaksi berbagai faktor, mulai dari kondisi makroekonomi, kebijakan moneter, kinerja fundamental perusahaan, hingga sentimen pasar yang seringkali bersifat tidak rasional [2]. Karakteristik tersebut menjadikan data harga saham tergolong sebagai deret waktu yang kompleks, seringkali menunjukkan perilaku non-stasioner, adanya komponen tren jangka panjang, pola musiman periodik, serta fluktuasi tidak beraturan yang sulit diprediksi. Tantangan ini mendorong berkembangnya berbagai pendekatan kuantitatif dan statistik untuk memodelkan serta meramalkan pergerakan harga saham secara lebih akurat [3].

Dalam literatur analisis deret waktu, model *Autoregressive Integrated Moving Average* (ARIMA) yang diperkenalkan oleh Box dan Jenkins [3] telah lama menjadi standar dalam peramalan data keuangan. Model ini mampu menangkap struktur autokorelasi dalam data stasioner dan telah banyak diterapkan pada berbagai konteks pasar keuangan [4]. Namun, model ARIMA memiliki keterbatasan dalam menangani komponen musiman yang kompleks dan non-linear, sehingga melahirkan ekstensi berupa model *Seasonal ARIMA* (SARIMA) [5]. Meskipun SARIMA mampu mengakomodasi pola musiman, model ini tetap mengasumsikan linearitas hubungan antar komponen deret waktu, yang tidak selalu terpenuhi pada data harga saham yang sangat dinamis.

Perkembangan metode *machine learning* dan pendekatan berbasis dekomposisi kemudian membuka alternatif baru dalam analisis deret waktu. Metode seperti *Long Short-Term Memory* (LSTM) [6] dan *Gradient Boosting* [7] telah menunjukkan performa yang menjanjikan pada berbagai kasus peramalan deret waktu keuangan. Namun, metode-metode tersebut umumnya membutuhkan volume data yang besar, proses *hyperparameter tuning* yang kompleks, serta tingkat interpretabilitas yang relatif rendah bagi pengguna non-teknis. Oleh karena itu, diperlukan metode yang mampu menyeimbangkan akurasi prediktif dengan kemudahan interpretasi dan implementasi.

Facebook Prophet, yang dikembangkan oleh Taylor dan Letham [8] dari tim *Core Data Science* Meta Platforms, merupakan model peramalan deret waktu berbasis dekomposisi aditif yang dirancang untuk menangani data dengan tren yang tidak linear, komponen musiman berganda, serta efek hari libur secara otomatis. Prophet memformulasikan deret waktu sebagai penjumlahan tiga komponen utama: tren $g(t)$, musiman $s(t)$, dan efek hari libur $h(t)$, yang dinyatakan sebagai

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t,$$

di mana ε_t merupakan komponen galat. Model ini telah terbukti menghasilkan peramalan yang robust pada berbagai domain, termasuk data bisnis, cuaca, dan keuangan [8]. Kelebihan utama Prophet dibandingkan metode konvensional adalah kemampuannya mendeteksi titik-titik perubahan tren (*changepoints*) secara otomatis serta menangani data hilang tanpa memerlukan imputasi manual [8].

Sejumlah penelitian terdahulu telah menerapkan Prophet pada data keuangan dan pasar saham.

Garlapati et al. [Garlapati2021] menunjukkan bahwa Prophet menghasilkan akurasi yang kompetitif dibandingkan ARIMA pada data saham harian. Prophet mengungguli ARIMA khususnya pada data yang memiliki komponen musiman dan tren non-linear yang kuat.

Jin et al. [Jin2022] menerapkan Prophet dan ARIMA pada data harga penutupan saham Google dan menemukan bahwa Prophet unggul dalam peramalan jangka menengah pada kondisi pasar yang relatif stabil.

Setiawan et al. [Setiawan2023] membandingkan ARIMA dan LSTM pada data saham perbankan Indonesia, termasuk BBKA, dan menemukan bahwa pemilihan model yang tepat bergantung pada karakteristik spesifik data masing-masing saham. Penelitian-penelitian tersebut memperkuat relevansi penggunaan Prophet sebagai metode peramalan pada data harga saham Indonesia, termasuk saham BBKA.JK yang memiliki karakteristik tren meningkat jangka panjang disertai pola musiman harian dan mingguan yang relatif stabil.

Uji stasioneritas merupakan tahap prapemrosesan yang esensial dalam analisis deret waktu. Data yang non-stasioner mengandung tren atau varians yang berubah sepanjang waktu, sehingga model yang dibangun tanpa mengatasi non-stasioneritas akan menghasilkan estimasi yang *spurious* [9]. Augmented Dickey-Fuller (ADF) test [10] merupakan uji yang paling umum digunakan untuk mendeteksi unit root sebagai indikator non-stasioneritas. Dengan hipotesis nol berupa keberadaan unit root, penolakan H_0 pada taraf signifikansi tertentu mengindikasikan bahwa data bersifat stasioner. Hasil uji ADF ini akan menjadi dasar pertimbangan dalam tahap pemodelan, khususnya untuk memahami karakteristik dasar data harga saham BBKA.JK sebelum diterapkan pada model Prophet.

Evaluasi kinerja model peramalan dilakukan menggunakan tiga metrik statistik yang umum digunakan dalam literatur, yaitu *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE) [11]. Ketiga metrik ini dipilih karena masing-masing memberikan perspektif yang berbeda terhadap galat peramalan: MAE mengukur rata-rata besarnya galat absolut, RMSE memberikan penalti lebih besar terhadap galat yang besar, sedangkan MAPE mengekspresikan galat dalam satuan persentase sehingga memudahkan interpretasi lintas konteks.

Berdasarkan uraian di atas, penelitian ini bertujuan untuk menganalisis dan meramalkan harga penutupan saham BBKA.JK menggunakan metode Facebook Prophet pada data harian periode 1 Januari 2019 hingga 8 Mei 2026 dengan total 1.787 observasi. Secara spesifik, penelitian ini mencakup eksplorasi dan visualisasi data, identifikasi komponen tren dan musiman, uji stasioneritas menggunakan ADF test, pemodelan dengan Prophet, evaluasi kinerja model, serta peramalan harga saham untuk lima hari perdagangan ke depan sebagai informasi pendukung pengambilan keputusan investasi. Penelitian ini diharapkan memberikan kontribusi praktis bagi investor individual maupun institusional yang memerlukan referensi berbasis data dalam mengambil keputusan investasi pada saham BBKA.JK, sekaligus memperkaya literatur terapan analisis deret waktu dalam konteks pasar modal Indonesia.

Sistematika penulisan artikel ini disusun sebagai berikut. Bagian 2 memaparkan tinjauan pustaka yang menjadi landasan teoretis penelitian. Bagian 3 menjelaskan metodologi yang digunakan, mencakup sumber data, prosedur pemodelan, dan kriteria evaluasi. Bagian 4 menyajikan hasil analisis dan pembahasan secara komprehensif. Bagian 5 menutup artikel dengan kesimpulan dan rekomendasi berbasis hasil analisis.

2 Tinjauan Pustaka

2.1 Pasar Modal dan Perilaku Harga Saham

Pasar modal merupakan mekanisme yang memungkinkan perusahaan untuk memperoleh pendanaan jangka panjang melalui penerbitan instrumen keuangan seperti saham dan obligasi, sekaligus memberikan kesempatan bagi investor untuk memperoleh imbal hasil dari modal yang ditanamkan [1]. Dalam konteks teori keuangan, perilaku harga saham telah lama dikaitkan dengan konsep *Efficient Market Hypothesis* (EMH) yang dikemukakan oleh Fama [2]. EMH menyatakan bahwa harga saham pada setiap saat mencerminkan seluruh informasi yang tersedia, sehingga tidak ada investor yang secara konsisten dapat memperoleh keuntungan abnormal melalui analisis historis harga. Meskipun demikian, berbagai studi empiris selanjutnya telah menunjukkan adanya anomali pasar yang bertentangan dengan bentuk lemah EMH, sehingga membuka ruang bagi pendekatan kuantitatif berbasis data historis untuk memodelkan dan meramalkan pergerakan harga saham [3].

2.2 Analisis Deret Waktu dalam Konteks Keuangan

Analisis deret waktu merupakan bidang statistik yang mempelajari pola dan struktur data yang diamati secara berurutan dalam waktu. Dalam konteks pasar keuangan, data harga saham merupakan salah satu contoh deret waktu yang paling banyak diteliti. Hyndman dan Athanasopoulos [5] mendefinisikan komponen utama deret waktu yang mencakup tren, musiman, siklus, dan komponen residual atau tidak beraturan. Identifikasi yang tepat terhadap komponen-komponen tersebut merupakan langkah penting sebelum memilih model peramalan yang sesuai.

Sebelum melakukan pemodelan, uji stasioneritas merupakan tahap diagnostik yang esensial. Data deret waktu dikatakan stasioner apabila rata-rata, varians, dan struktur autokovariansinya tidak berubah sepanjang waktu [5]. Dickey dan Fuller [10] mengembangkan uji formal untuk mendeteksi keberadaan *unit root* dalam proses autoregresif, yang kemudian dikenal sebagai uji Augmented Dickey-Fuller (ADF). Dalam uji ini, hipotesis nol menyatakan bahwa data mengandung *unit root* (non-stasioner), sehingga penolakan H_0 pada tingkat signifikansi tertentu mengindikasikan stasioneritas data. Uji ADF telah menjadi standar dalam analisis deret waktu keuangan karena kemampuannya mengakomodasi struktur autokorelasi melalui penambahan lag diferensial dalam persamaan regresi.

2.3 Facebook Prophet sebagai Model Peramalan Berbasis Dekomposisi

Facebook Prophet merupakan prosedur peramalan deret waktu yang dikembangkan oleh Taylor dan Letham [8] dari tim *Core Data Science* Meta Platforms (dahulu Facebook). Prophet didesain sebagai model dekomposisi aditif yang memformulasikan deret waktu sebagai

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t, \quad (1)$$

di mana $g(t)$ merepresentasikan komponen tren yang dapat berupa model pertumbuhan linear dengan titik-titik perubahan (*change points*) atau model pertumbuhan logistik, $s(t)$ merepresentasikan komponen musiman yang dimodelkan menggunakan deret Fourier, $h(t)$ merepresentasikan efek hari libur dan kejadian khusus, serta ε_t merupakan komponen galat yang diasumsikan berdistribusi normal [8].

Keunggulan utama Prophet dibandingkan model konvensional terletak pada beberapa aspek. Pertama, Prophet mampu mendeteksi titik-titik perubahan tren secara otomatis menggunakan pendekatan *Laplace prior* pada parameter perubahan, sehingga lebih adaptif terhadap pergeseran pola tren jangka panjang. Kedua, model ini robust terhadap data yang hilang (*missing data*) dan *outlier*, dua permasalahan yang sering dijumpai pada data harga saham harian. Ketiga, prophet memungkinkan analisis untuk mengintegrasikan pengetahuan domain secara eksplisit melalui spesifikasi *change points* dan efek hari libur yang diketahui [8].

2.4 Penerapan Prophet pada Data Saham dan Deret Waktu Keuangan

Garlapati et al. [12] membandingkan Prophet dan ARIMA dalam peramalan harga saham dan menyimpulkan bahwa keduanya memiliki performa yang kompetitif, dengan Prophet menunjukkan keunggulan pada data yang mengandung komponen musiman dan tren non-linear yang jelas. Jin et al. [13] menerapkan Prophet dan ARIMA pada data harga penutupan saham Google selama periode pandemi COVID-19 dan menemukan bahwa model ARIMA memiliki akurasi yang sedikit lebih baik selama periode ketidakpastian tinggi, sementara Prophet unggul dalam peramalan jangka menengah dengan data pra-pandemi.

Penelitian yang sangat relevan dengan topik ini dilakukan oleh Wulandari et al. yang dikutip dalam [14], di mana metode ARIMA diterapkan pada fluktuasi harga saham PT Bank Central

Asia Tbk dan menunjukkan bahwa data BBKA memiliki struktur deret waktu yang dapat dimodelkan dengan baik menggunakan pendekatan statistik. Penelitian-penelitian tersebut secara kolektif menunjukkan bahwa pemilihan metode peramalan untuk data saham BBKA.JK perlu mempertimbangkan karakteristik spesifik data, termasuk keberadaan tren jangka panjang, pola musiman harian dan mingguan pada data frekuensi tinggi, serta sensitivitas terhadap kejadian luar biasa seperti krisis keuangan dan pandemi.

2.5 Kriteria Evaluasi Model Peramalan

Evaluasi kualitas model peramalan merupakan tahap kritis yang menentukan apakah model yang dibangun layak digunakan dalam pengambilan keputusan. Hyndman dan Koehler [11] secara sistematis meninjau berbagai ukuran akurasi peramalan dan mengidentifikasi kondisi-kondisi di mana setiap metrik dapat menghasilkan penilaian yang keliru. Tiga metrik yang paling umum digunakan dalam literatur peramalan deret waktu keuangan adalah *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE), yang masing-masing didefinisikan sebagai

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|, \quad (2)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}, \quad (3)$$

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100\%, \quad (4)$$

di mana y_t adalah nilai aktual, $\hat{y}_t$ adalah nilai ramalan, dan n adalah jumlah observasi dalam periode evaluasi. MAE memberikan penalti yang proporsional terhadap besar galat, RMSE memberikan penalti yang lebih besar untuk galat yang ekstrem karena sifat kuadratnya, sedangkan MAPE menyatakan galat dalam satuan persentase relatif terhadap nilai aktual sehingga memudahkan interpretasi dan perbandingan lintas konteks [11]. Lewis [15] menetapkan panduan interpretasi nilai MAPE, di mana nilai MAPE di bawah 10% mengindikasikan peramalan yang sangat akurat, 10–20% tergolong akurat, 20–50% tergolong cukup akurat, dan di atas 50% tergolong tidak akurat.

3 Methodology

This section outlines the comprehensive technical framework and statistical methodologies employed to model and forecast the daily closing prices of PT Bank Central Asia Tbk (BBKA.JK) as implemented in the empirical analysis [8]. The proposed workflow integrates rigorous data preprocessing, statistical stationarity testing via the Augmented Dickey-Fuller (ADF) method, and predictive modeling utilizing the Facebook Prophet additive framework.

3.1 Data Preprocessing and Stationarity Testing

Financial time series data frequently exhibit anomalies, missing records, or irregular intervals due to market holidays and reporting latencies. Let Y_t represent the raw closing price of the asset at day t , and V_t represent the corresponding trading volume. To ensure structural integrity, the historical data is first chronologically sorted such that $t = 1, 2, \dots, T$.

To address missing or anomalous zero-volume records resulting from non-trading days, a sequential two-way imputation scheme is implemented. First, a forward fill (*ffill*) operation propagates the last observed valid observation forward to handle zero-volume instances:

$$V_t = V_{t-1} \quad \text{if } V_t \in \{0, \text{NaN}\} \quad (5)$$

Remaining missing elements at the boundary are resolved using a backward fill (*bfill*) mechanism, ensuring a continuous and complete series.

Prior to entering the predictive model, the stationarity of the target time series Y_t must be formally evaluated. A time series is strictly stationary if its joint probability distribution is invariant under time shifts. We implement the Augmented Dickey-Fuller (ADF) test [10] to detect the presence of a unit root. The test is formulated via the following regression equation:

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^p \delta_i \Delta Y_{t-i} + \epsilon_t \quad (6)$$

where Δ is the first-difference operator ($\Delta Y_t = Y_t - Y_{t-1}$), α is a constant drift, β is the coefficient on a time trend, p is the lag order of the autoregressive process, and ϵ_t is an independent white noise error term. The hypothesis framework is defined as:

- $H_0 : \gamma = 0$ (The process possesses a unit root and is non-stationary).
- $H_1 : \gamma < 0$ (The process is stationary).

If the empirical test statistic fails to fall below the critical value or if the corresponding p -value satisfies $p > 0.05$, the null hypothesis cannot be rejected, indicating a non-stationary process characterized by a stochastic trend.

3.2 The Facebook Prophet Forecasting Framework

Given the non-linear and non-stationary nature of asset prices, we utilize the Facebook Prophet forecasting model developed by Taylor and Letham [8]. Prophet bypasses the rigid assumptions of traditional autoregressive models by modeling the time series as a generalized additive model (GAM). The target variable $y(t)$, representing the daily closing price at time t , is decomposed into three primary structural components and an error term:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (7)$$

where $g(t)$ is the trend function, $s(t)$ represents periodic seasonal changes, $h(t)$ denotes the effect of holidays or specific calendar events, and ϵ_t represents the idiosyncratic error term.

3.2.1 Trend Component $g(t)$

The long-term movement of financial prices is captured via a piecewise linear growth model, which accommodates shifts in the growth rate through automatically selected changepoints:

$$g(t) = (k + a(t)^T \delta)t + (m + a(t)^T \gamma) \quad (8)$$

where k is the initial growth rate, δ is a vector of rate adjustments at specific changepoint times, m is the intercept parameter, and $a(t) \in \{0, 1\}^K$ is a binary vector indicating whether time t has passed each of the K *changepoints*. The vector γ is defined to ensure continuity of the function across boundaries.

3.2.2 Seasonality Component $s(t)$

To model periodic fluctuations—such as weekly trading cycles or annual market effects—Prophet utilizes a standard Fourier series to approximate arbitrary seasonal behaviors:

$$s(t) = \sum_{n=1}^N \left(A_n \cos\left(\frac{2\pi nt}{P}\right) + B_n \sin\left(\frac{2\pi nt}{P}\right) \right) \quad (9)$$

where P is the base period ($P = 7$ for weekly dynamics, $P = 365.25$ for annual trends), and N represents the maximum frequency parameter.

3.3 Model Evaluation Metrics

To evaluate the predictive performance of the trained Prophet architecture against unseen testing data, three quantitative statistical metrics are computed [11]: Mean Absolute Error (MAE), Mean Squared Error (MSE), and Mean Absolute Percentage Error (MAPE). Let y_i denote the true observed closing price, $\hat{y}_i$ represent the predicted price, and n denote the total number of evaluation periods.

1. **Mean Absolute Error (MAE):** Measures the average magnitude of absolute residuals:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$

2. **Mean Squared Error (MSE):** Penalizes larger forecasting errors more heavily:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (11)$$

3. **Mean Absolute Percentage Error (MAPE):** Provides a relative measure of accuracy expressed as a percentage:

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (12)$$

4 Empirical Results/Experiments

This section presents the empirical findings obtained from the statistical analysis and forecasting models applied to the PT Bank Central Asia Tbk (BBKA.JK) stock price dataset. The analysis begins with a formal stationarity assessment, followed by model training, validation, and out-of-sample forecasting evaluation.

4.1 Stationarity Analysis and Data Partitioning

To evaluate the structural properties of the BBKA closing price time series, we perform an Augmented Dickey-Fuller (ADF) test to check for the presence of a unit root [10]. The total dataset comprises $N = 1,783$ daily observations. Table 1 summarizes the empirical test statistic alongside the corresponding critical values at the 1%, 5%, and 10% significance levels.

Table 1: Augmented Dickey-Fuller (ADF) Test Results for BBKA Closing Prices

Statistical Parameter / Metric	Value	<i>p</i> -value
ADF Test Statistic	-1.7121	0.4249
Critical Value (1%)	-3.4340	
Critical Value (5%)	-2.8632	
Critical Value (10%)	-2.5676	
Number of Lags Used	2	
Total Observations (<i>N</i>)	1,783	

As demonstrated in Table 1, the empirical ADF test statistic of -1.7121 is visibly greater than the critical values at all conventional significance levels (e.g., -2.8632 at the 5% level). Furthermore, the calculated *p*-value is 0.4249, which drastically exceeds the standard significance threshold ($\alpha = 0.05$). Consequently, we fail to reject the null hypothesis (H_0), confirming that the asset's closing price series possesses a unit root and is non-stationary, exhibiting a strong stochastic upward trend over time.

For model implementation, the dataset is partitioned into a training set and a testing set. To maintain historical continuity while allowing for precise short-term validation, the first 1,781 observations are designated as the training data to optimize the model parameters, while the remaining 5 periods are withheld as the out-of-sample testing framework to assess predictive power.

4.2 Forecasting Performance Evaluation

Using the additive framework of the Facebook Prophet model [8], the dynamic trends and seasonal variations are fully estimated. The predictive accuracy of the model over the out-of-sample testing horizon is evaluated using three standard metrics [11]: Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), and Mean Absolute Percentage Error (MAPE). The quantitative evaluation output is summarized in Table 2.

Table 2: Prophet Model Out-of-Sample Forecasting Performance

Evaluation Metric	Empirical Value
Mean Absolute Error (MAE)	582.6611
Root Mean Squared Error (RMSE)	598.0191
Mean Absolute Percentage Error (MAPE)	0.0970

The empirical validation indicators in Table 2 establish that the Prophet model yields a highly robust predictive performance. The MAE and RMSE values reflect modest absolute deviations relative to the actual trading nominal value of BBKA shares. Most notably, the model achieves a remarkably low MAPE of 0.0970%, indicating a high degree of precision in capturing the directional trajectory of the asset over the 5-period horizon.

Figure 1 visually illustrates the actual historical trend alongside the calculated prediction intervals. The model successfully adapts to the underlying market patterns without overfitting the structural components, maintaining consistent prediction limits.




Figure 1: Historical closing prices and out-of-sample Prophet model projections for BBKA stock

5 Kesimpulan

Berdasarkan hasil analisis dan evaluasi model, dapat disimpulkan bahwa metode Facebook Prophet mampu menangkap pola tren dan musiman pada data harga penutupan BBKA.JK dengan performa yang baik pada peramalan jangka pendek. Model ini memberikan referensi awal yang berguna bagi investor dalam mengamati kecenderungan pergerakan harga saham BBKA.JK. Penelitian lanjutan dapat mengeksplorasi kombinasi Prophet dengan variabel eksternal atau model lain untuk meningkatkan akurasi peramalan.

References

- [1] E. Tandelilin. *Portofolio dan Investasi: Teori dan Aplikasi*. 1st ed. Yogyakarta: Kanisius, 2010.
- [2] E. F. Fama. "Efficient Capital Markets: A Review of Theory and Empirical Work". In: *The Journal of Finance* 25.2 (1970), pp. 383–417. DOI: [10.1111/j.1540-6261.1970.tb00518.x](https://doi.org/10.1111/j.1540-6261.1970.tb00518.x).
- [3] G. E. P. Box et al. *Time Series Analysis: Forecasting and Control*. 5th ed. Hoboken, New Jersey: John Wiley & Sons, 2015.
- [4] P. Mondal, L. Shit, and S. Goswami. "Study of Effectiveness of Time Series Modeling (ARIMA) in Forecasting Stock Prices". In: *International Journal of Computer Science, Engineering and Applications* 4.2 (2014), pp. 13–29. DOI: [10.5121/ijcsea.2014.4202](https://doi.org/10.5121/ijcsea.2014.4202).
- [5] R. J. Hyndman and G. Athanasopoulos. *Forecasting: Principles and Practice*. 2nd ed. Melbourne, Australia: OTexts, 2018.
- [6] S. Hochreiter and J. Schmidhuber. "Long Short-Term Memory". In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: [10.1162/neco.1997.9.8.1735](https://doi.org/10.1162/neco.1997.9.8.1735).

- [7] T. Chen and C. Guestrin. “XGBoost: A Scalable Tree Boosting System”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [8] S. J. Taylor and B. Letham. “Forecasting at Scale”. In: *The American Statistician* 72.1 (2018), pp. 37–45. DOI: [10.1080/00031305.2017.1380080](https://doi.org/10.1080/00031305.2017.1380080).
- [9] C. W. J. Granger and P. Newbold. “Spurious Regressions in Econometrics”. In: *Journal of Econometrics* 2 (2 1974), pp. 111–120. DOI: [10.1016/0304-4076\(74\)90034-7](https://doi.org/10.1016/0304-4076(74)90034-7).
- [10] D. A. Dickey and W. A. Fuller. “Distribution of the Estimators for Autoregressive Time Series with a Unit Root”. In: *Journal of the American Statistical Association* 74.366 (1979), pp. 427–431. DOI: [10.2307/2286348](https://doi.org/10.2307/2286348).
- [11] R. J. Hyndman and A. B. Koehler. “Another Look at Measures of Forecast Accuracy”. In: *International Journal of Forecasting* 22.4 (2006), pp. 679–688. DOI: [10.1016/j.ijforecast.2006.03.001](https://doi.org/10.1016/j.ijforecast.2006.03.001).
- [12] A. Garlapati et al. “Stock Price Prediction Using Facebook Prophet and ARIMA Models”. In: *2021 6th International Conference for Convergence in Technology (I2CT)*. IEEE, 2021, pp. 1–7. DOI: [10.1109/I2CT51068.2021.9418208](https://doi.org/10.1109/I2CT51068.2021.9418208).
- [13] B. Jin, S. Gao, and Z. Tao. “ARIMA and Facebook Prophet Model in Google Stock Price Prediction”. In: *Proceedings of Business and Economic Studies* 5.5 (2022). DOI: [10.26689/pbes.v5i5.4386](https://doi.org/10.26689/pbes.v5i5.4386).
- [14] F. A. Kurnia et al. “Analisis Prediksi Harga Saham PT. BCA Dengan Menggunakan Metode ARIMA”. In: *eCo-Fin: Economics and Financial* 7.2 (2025), pp. 886–896.
- [15] C. D. Lewis. *Industrial and Business Forecasting Methods*. London: Butterworths, 1982.